

RAPPORT DE LITTÉRATURE — STAGE DE RECHERCHE #02-2026

Vision par Ordinateur et Intelligence Artificielle Embarquée

Caplogy Innovation — Fès, Maroc

Méthodes de Post-Traitement en Détection d'Objets :

De la Suppression par Maximum Local au Pipeline End-to-End NMS-Free — Principes, Hypothèses, Limitations —

Entreprise Caplogy Innovation, Fès, Maroc

Encadrant y.zardoua@caplogy.com

Référence Stage#02-2026

Période Janvier – Juillet 2026

Date Mars 2026

Version V5 — Version Finale et Définitive

Résumé exécutif

Ce rapport étudie de manière exhaustive les méthodes de fusion et de suppression de boîtes englobantes utilisées en post-traitement dans les détecteurs d'objets modernes, selon la structure suivante : **NMS Standard**, **Soft-NMS**, **DIOU-NMS**, **Adaptive NMS**, **BBR (Bounding Box Refinement)**, **WBF (Weighted Box Fusion)**, **NMS-Free dans YOLO26**. Pour chaque méthode : *principe algorithmique*, *hypothèses implicites* et *analyse des limitations*. La section NMS-Free comprend en outre une discussion sur l'intégration avec les images fisheye dans le contexte précis de ce stage. Sources NMS-Free : [10, 11, 12, 13, 14].

Note de transparence : YOLO26 a été publié en janvier 2026. Ce rapport s'appuie sur la documentation officielle Ultralytics [11] et sur trois analyses indépendantes récentes [12, 13, 14]. Toute affirmation relative à YOLO26 est explicitement citée.

Contents

1	Notions Préliminaires	3
1.1	Intersection over Union (IoU)	3
1.2	Métriques d'évaluation	3
1.3	Contexte du stage	3
2	NMS Standard (Greedy-NMS)	4
2.1	Principe	4
2.2	Hypothèses	5
2.3	Analyse des limitations	5
2.4	Résultats quantitatifs (NMS Standard comme baseline)	5
3	Soft-NMS	7
3.1	Principe	7
3.2	Hypothèses	8
3.3	Analyse des limitations	8
4	DIoU-NMS	9
4.1	Principe	9
4.2	Hypothèses	9
4.3	Analyse des limitations	10
4.4	Résultats quantitatifs	10
5	Adaptive NMS	12
5.1	Principe	12
5.2	Hypothèses	12
5.3	Analyse des limitations	13
6	Bounding Box Refinement (BBR)	14
6.1	Principe	14
6.1.1	Évolution des fonctions de perte	14
6.1.2	Raffinement itératif à l'inférence	15
6.2	Hypothèses	15
6.3	Analyse des limitations	15
6.4	Résultats quantitatifs	16
6.4.1	Gains des fonctions de perte BBR	16
6.4.2	Raffinement itératif — Cascade R-CNN	16
6.4.3	BBR dans les détecteurs YOLO	17

7	Weighted Box Fusion (WBF)	18
7.1	Principe	18
7.2	Hypothèses	19
7.3	Analyse des limitations	19
8	NMS-Free : Inférence End-to-End sans Post-Traitement	20
8.1	Contexte et motivation	20
8.2	YOLOv10 : Consistent Dual Assignments (NeurIPS 2024)	20
8.2.1	Innovation centrale	20
8.3	YOLO26 : NMS-Free Natif et Optimisations Edge	21
8.3.1	Vue d'ensemble	21
8.3.2	Innovation 1 — Suppression de la DFL	21
8.3.3	Innovation 2 — ProgLoss	22
8.3.4	Innovation 3 — STAL	22
8.3.5	Innovation 4 — Optimiseur MuSGD	22
8.4	Hypothèses	23
8.5	Analyse des limitations	23
8.6	Intégration NMS-Free avec les Images Fisheye	24
8.6.1	Contexte du pipeline fisheye multi-projections	24
8.6.2	Apport de YOLO26 NMS-Free au niveau intra-projection	24
8.6.3	Pipeline proposé : YOLO26 + WBF pondéré	25
8.6.4	Points d'attention pour l'intégration	25
9	Analyse Comparative et Synthèse	26
10	Conclusion	26
	Références	28

1 Notions Préliminaires

1.1 Intersection over Union (IoU)

Définition — IoU

L'IoU mesure le chevauchement entre deux boîtes A et B :

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|} \in [0, 1] \quad (1.1)$$

$\text{IoU} = 0$ indique l'absence de chevauchement ; $\text{IoU} = 1$ une superposition parfaite. L'IoU est la métrique d'évaluation universelle des détecteurs d'objets.

1.2 Métriques d'évaluation

Définition — Métriques

AP / mAP : Average Precision moyennée sur les classes, calculée sous la courbe Précision-Rappel. Le protocole COCO intègre les seuils $\text{IoU} \in [0.50, 0.95]$; le protocole PASCAL VOC utilise $\text{IoU} = 0.50$.

MR⁻² : taux de détections manquées à 10^{-2} faux positifs par image. Utilisé sur CrowdHuman et CityPersons. *Plus bas est meilleur.*

Latence E2E : temps total d'inférence *incluant* le post-traitement. Critique pour les systèmes temps-réel embarqués.

1.3 Contexte du stage

Ce stage porte sur la détection de piétons depuis un drone équipé d'une caméra fisheye 180°. L'approche adoptée génère N projections gnomoniques depuis l'image fisheye, applique un détecteur sur chaque projection, puis reprojette les boîtes dans le référentiel fisheye. Ce pipeline multi-vues produit des détections *redondantes et géométriquement décalées* (phénomène de *jitter*), motivant l'étude approfondie des méthodes de fusion présentées ici.

2 NMS Standard (Greedy-NMS)

2.1 Principe

Introduite par Neubeck & Van Gool à ICPR 2006 [1], la **Non-Maximum Suppression standard** est l'algorithme glouton séquentiel suivant : sélectionner itérativement la boîte de score maximum, la conserver, puis **supprimer** définitivement toutes les boîtes qui lui chevauchent au-delà d'un seuil $\mathcal{N}_t$.

Algorithm 2.1 NMS Standard (Greedy-NMS)

Entrées : Boîtes $\mathcal{B} = \{b_i\}$, scores $\mathcal{S} = \{c_i\}$, seuil de confiance τ_c , seuil IoU $\mathcal{N}_t$

Sorties : Ensemble $\mathcal{D}$ de détections finales

```

1:  $\mathcal{B} \leftarrow \{b_i \mid c_i \geq \tau_c\}$ 
2: Trier  $\mathcal{B}$  par scores décroissants
3:  $\mathcal{D} \leftarrow \emptyset$ 
4: while  $\mathcal{B} \neq \emptyset$  do
5:    $M \leftarrow \arg \max_{b_i \in \mathcal{B}} c_i$ 
6:    $\mathcal{D} \leftarrow \mathcal{D} \cup \{M\}; \quad \mathcal{B} \leftarrow \mathcal{B} \setminus \{M\}$ 
7:   for chaque  $b_i \in \mathcal{B}$  do
8:     if  $\text{IoU}(M, b_i) \geq \mathcal{N}_t$  then
9:        $\mathcal{B} \leftarrow \mathcal{B} \setminus \{b_i\}$  ▷ Suppression binaire irréversible
10:    end if
11:  end for
12: end while return  $\mathcal{D}$ 

```

Formellement, la règle de mise à jour du score est :

$$c_i \leftarrow c_i \cdot \mathbf{1}[\text{IoU}(M, b_i) < \mathcal{N}_t] \quad (2.1)$$

La complexité est $O(n^2)$ dans le pire cas, et l'exécution est **séquentielle** : chaque itération dépend du résultat de la précédente.

2.2 Hypothèses

Hypothèses implicites de NMS Standard

1. **H1 — Corrélacion score/localisation** : la boîte ayant le score de classification le plus élevé est nécessairement la mieux localisée. Cette hypothèse est réfutée empiriquement [3] : le score de classification n'est pas corrélé à la qualité de localisation.
2. **H2 — Exclusivité locale** : deux boîtes avec $\text{IoU} \geq \mathcal{N}_t$ correspondent forcément au même objet. Incorrecte en scènes denses et en contexte multi-projections fisheye où plusieurs vues détectent le même piéton.
3. **H3 — Stationnarité du seuil** : $\mathcal{N}_t$ est optimal uniformément sur toute l'image, indépendamment de la densité locale des objets.
4. **H4 — Indépendance des classes** : NMS est appliqué par classe, supposant l'absence d'interaction géométrique entre classes distinctes.

2.3 Analyse des limitations

Limitations de NMS Standard

1. **Décision binaire irréversible** : toute information géométrique portée par les boîtes supprimées est définitivement perdue. Il n'existe aucun mécanisme de fusion ; la précision de localisation ne peut pas être améliorée.
2. **Échec systématique en scènes denses** : lorsque deux piétons distincts ont des boîtes se chevauchant au-delà de $\mathcal{N}_t$, l'un est inévitablement supprimé, produisant un faux négatif structurel.
3. **Sensibilité critique au seuil $\mathcal{N}_t$** : aucune valeur universelle n'existe. Un seuil trop bas multiplie les faux négatifs ; un seuil trop élevé laisse passer les faux positifs. La calibration doit être répétée pour chaque domaine.
4. **Inadaptation au pipeline multi-vues fisheye** : les boîtes reprojétées du même piéton depuis différentes projections gnomoniques sont légèrement décalées ; NMS en supprimerait certaines arbitrairement, amplifiant le jitter plutôt que de le réduire.
5. **Complexité $O(n^2)$ séquentielle** : non parallélisable nativement, goulot d'étranglement à l'inférence sur GPU et obstacle à l'export (ONNX, TensorRT, CoreML).

2.4 Résultats quantitatifs (NMS Standard comme baseline)

NMS Standard est la référence universelle contre laquelle toutes les méthodes sont comparées. Les chiffres ci-dessous illustrent ses performances absolues et servent de

point de comparaison pour les sections suivantes.

Table 2.1: NMS Standard comme baseline — détecteurs de référence sur MS-COCO et benchmarks piétons [7, 4, 2].

Détecteur	Dataset	NMS Standard	Seuil $\mathcal{N}_t$	Métrique
Faster R-CNN (VGG-16)	MS-COCO val	24.4	0.50	mAP _{50:95}
R-FCN (ResNet-101)	MS-COCO val	31.1	0.50	mAP _{50:95}
Faster R-CNN (VGG-16)	PASCAL VOC	73.4	0.50	mAP ₅₀
Faster R-CNN	CityPersons	13.0	0.50	MR ⁻² (↓)
Faster R-CNN	CrowdHuman	53.1	0.50	MR ⁻² (↓)
YOLOv8n	MS-COCO val	37.3	0.45	mAP _{50:95}
YOLO11n	MS-COCO val	39.5	0.45	mAP _{50:95}

Table 2.2: Impact du seuil $\mathcal{N}_t$ sur les performances de NMS Standard — Faster R-CNN sur PASCAL VOC [2].

Seuil $\mathcal{N}_t$	mAP ₅₀ (%)	Observation
0.30	69.8	Trop bas : faux négatifs en scènes denses
0.40	72.1	Sous-optimal
0.50	73.4	Valeur par défaut couramment utilisée
0.60	72.9	Légère dégradation
0.70	70.3	Trop élevé : faux positifs multipliés

Ces deux tableaux illustrent la **sensibilité critique** de NMS au choix de $\mathcal{N}_t$ (limitation #3) et positionnent les valeurs absolues qui seront comparées aux méthodes améliorées dans les sections suivantes.

3 Soft-NMS

3.1 Principe

Proposé par Bodla *et al.* à ICCV 2017 [2], **Soft-NMS** est une évolution directe de NMS Standard : au lieu de supprimer binairement une boîte, il **dégrade continûment** son score de confiance en fonction de son chevauchement avec la boîte de référence M .

Variante linéaire :

$$c_i \leftarrow c_i \cdot (1 - \text{IoU}(M, b_i)), \quad \text{si } \text{IoU}(M, b_i) \geq \mathcal{N}_t \quad (3.1)$$

Variante gaussienne (préférée en pratique) :

$$c_i \leftarrow c_i \cdot \exp\left(-\frac{\text{IoU}(M, b_i)^2}{\sigma}\right), \quad \forall b_i \neq M \quad (3.2)$$

où $\sigma > 0$ est un hyperparamètre de bande passante. La variante gaussienne est **continue sans discontinuité** au seuil $\mathcal{N}_t$, contrairement à la variante linéaire. Une boîte est finalement éliminée si son score dégradé est inférieur à un seuil ϵ .




Figure 3.1: Fonctions de pondération. NMS standard supprime abruptement ; Soft-NMS gaussien dégrade continûment, préservant les détections partiellement chevauchantes.

Résultats quantitatifs issus de la publication originale [2] :

Table 3.1: Gains Soft-NMS vs NMS standard [2].

Détecteur	Dataset	NMS	Soft-NMS (gaussien)
Faster R-CNN	MS-COCO	24.4% mAP	25.5% (+1.1)
R-FCN	MS-COCO	31.1% mAP	32.4% (+1.3)
Faster R-CNN	PASCAL VOC	73.4% mAP	75.1% (+1.7)
R-FCN	PASCAL VOC	76.4% mAP	78.1% (+1.7)

3.2 Hypothèses

Hypothèses implicites de Soft-NMS

1. La probabilité qu'une boîte soit un vrai positif décroît **monotonement** avec son IoU avec M : plus le chevauchement est fort, moins la boîte est susceptible d'être une détection légitime indépendante.
2. Le score dégradé reste **interprétable comme une probabilité** : le seuil final ϵ peut encore discriminer vrais positifs et faux positifs après la dégradation gaussienne.
3. La dégradation gaussienne est une bonne approximation de la distribution réelle des chevauchements entre instances distinctes.

3.3 Analyse des limitations

Limitations de Soft-NMS

1. **Hyperparamètre σ supplémentaire** : sa calibration requiert une validation croisée par domaine.
2. **Ambiguïté des scores dégradés** : un objet réel dont le score a été fortement dégradé peut être éliminé par le seuil ϵ , créant des faux négatifs subtils.
3. **Aucune fusion de coordonnées** : la boîte M reste géométriquement inchangée ; l'information de localisation des boîtes voisines n'est pas exploitée.
4. **Complexité $O(n^2)$ séquentielle** : identique à NMS Standard, non parallélisable nativement.
5. **Sous-optimal en contexte multi-vues** : aucune prise en compte de la source des boîtes ni de leur fiabilité géométrique (distance au bord de la projection).

4 DIoU-NMS

4.1 Principe

Proposée par Zheng *et al.* à AAAI 2020 [5], **DIoU-NMS** remplace le critère d'IoU de NMS Standard par la **Distance-IoU (DIoU)**, qui intègre simultanément le chevauchement et la **distance euclidienne normalisée entre centres** :

$$\text{DIoU}(A, B) = \text{IoU}(A, B) - \frac{d(c_A, c_B)^2}{c^2} \quad (4.1)$$

où $d(c_A, c_B)$ est la distance euclidienne entre les centres de A et B , et c est la diagonale de la plus petite boîte englobant A et B .




Figure 4.1: DIoU : d = distance entre centres, c = diagonale de la boîte englobante commune. Un IoU élevé avec des centres éloignés indique deux objets distincts ; DIoU-NMS les préserve tous deux.

La boîte b_i est supprimée si $\text{DIoU}(M, b_i) > \mathcal{N}_t$. Puisque $\text{DIoU} \leq \text{IoU}$, le critère est **plus discriminant** : deux boîtes très chevauchantes mais dont les centres sont éloignés reçoivent une DIoU réduite et ne sont pas supprimées, ce qui est le comportement correct en scènes denses.

4.2 Hypothèses

Hypothèses implicites de DIoU-NMS

1. Deux boîtes du même objet ont leurs **centres proches** ; deux boîtes d'objets distincts ont leurs centres éloignés même en cas de fort chevauchement géométrique.
2. La distance euclidienne normalisée $d^2/c^2 \in [0, 1]$ est un indicateur fiable de la séparation spatiale entre instances.
3. Les objets cibles ont une forme compacte, pour laquelle la distance entre centres est représentative. Hypothèse moins valide pour des objets très allongés ou courbes.

4.3 Analyse des limitations

Limitations de DIOU-NMS

1. **Suppression binaire conservée** : malgré un critère amélioré, la décision reste binaire ; aucune fusion de coordonnées n'est effectuée.
2. **Instabilité numérique** : si $c \rightarrow 0$ (boîtes quasi-identiques), le terme d^2/c^2 diverge numériquement.
3. **Complexité $O(n^2)$ séquentielle** : identique à NMS Standard.
4. **Insuffisant pour les objets fortement orientés** : la distance centre-à-centre peut être un mauvais proxy pour des objets allongés

4.4 Résultats quantitatifs

DIOU-NMS est conçu comme un remplacement direct de la fonction d'IoU dans NMS Standard : il ne modifie pas l'architecture du détecteur et s'applique à l'inférence sans réentraînement. Les gains sont mesurés par rapport à NMS Standard avec IoU classique [5].

Table 4.1: DIOU-NMS vs NMS Standard : gains sur MS-COCO val [5].

Détecteur	Dataset	NMS Std	DIOU-NMS	Gain
YOLOv3 (608)	MS-COCO val	33.0	33.4	+0.4
SSD (512)	MS-COCO val	28.8	29.2	+0.4
Faster R-CNN (Res-50)	MS-COCO val	36.4	37.2	+0.8
Faster R-CNN (Res-101)	MS-COCO val	38.5	39.4	+0.9

Table 4.2: DIOU-NMS : impact sur la détection en scènes denses vs NMS Standard — Faster R-CNN sur CrowdHuman [5].

Méthode NMS	mAP ₅₀ (%)	Recall (%)	MR ⁻² (%)
NMS Standard ($\mathcal{N}_t = 0.5$)	80.1	88.5	43.2
NMS Standard ($\mathcal{N}_t = 0.7$)	80.8	89.4	41.6
DIOU-NMS ($\mathcal{N}_t = 0.7$)	81.7	90.3	40.8

Les gains de DIOU-NMS sont modérés (+0.4 à +0.9% mAP) mais **systématiques et sans coût supplémentaire** : DIOU-NMS est un remplacement direct, plug-and-play,

de NMS Standard.

5 Adaptive NMS

5.1 Principe

Proposé par Liu *et al.* à CVPR 2019 [4], **Adaptive NMS** résout la limitation de stationnarité du seuil (H3 de NMS Standard) en prédisant dynamiquement un seuil IoU individuel pour chaque boîte à partir d’une estimation apprise de la **densité locale** :

$$\mathcal{N}_t(b_i) = \max(\mathcal{N}_{t,\min}, d_i) \quad (5.1)$$

où $d_i \in [0, 1]$ est la densité locale prédite par une tête de réseau auxiliaire. En scène dense (d_i élevé), le seuil est relevé pour conserver les détections proches ; en scène éparse, il reste bas.

Table 5.1: Résultats d’Adaptive NMS sur les benchmarks piétons [4].

Détecteur	Dataset	NMS standard	Adaptive NMS
Faster R-CNN	CityPersons (val)	13.0% MR^{-2}	10.8% (−2.2)
SSD512	CityPersons (val)	18.2% MR^{-2}	16.0% (−2.2)
Faster R-CNN	CrowdHuman (val)	53.1% MR^{-2}	49.7% (−3.4)

5.2 Hypothèses

Hypothèses implicites d’Adaptive NMS

1. La densité locale d’objets peut être estimée de manière fiable à partir des caractéristiques visuelles extraites par le backbone du détecteur.
2. Il existe une relation **monotone** entre la densité estimée d_i et le seuil IoU optimal : plus la scène est dense, plus le seuil doit être élevé.
3. L’estimation de densité généralise bien hors de la distribution d’entraînement (autres scènes, autre caméra, fisheye...).

5.3 Analyse des limitations

Limitations d'Adaptive NMS

1. **Modification architecturale obligatoire** : une tête de prédiction de densité doit être intégrée au réseau. Impossible d'appliquer "plug-and-play" sur un modèle pré-entraîné sans réentraînement complet.
2. **Dégradation hors distribution** : si la densité est mal estimée (domaine fisheye non représenté à l'entraînement), les seuils adaptatifs peuvent être inadaptés.
3. **Complexité $O(n^2)$ séquentielle** : identique à NMS Standard, malgré l'adaptation du seuil.
4. **Aucune fusion de coordonnées** : la précision de localisation individuelle des boîtes n'est pas améliorée.

6 Bounding Box Refinement (BBR)

6.1 Principe

Le **Bounding Box Refinement (BBR)** désigne l'ensemble des méthodes qui améliorent la **précision de localisation** des boîtes englobantes, soit lors de l'entraînement via des *fonctions de perte géométriques*, soit lors de l'inférence via des *étapes itératives de raffinement*. BBR est **complémentaire** aux algorithmes NMS : NMS *filtre* les boîtes redondantes ; BBR *affine* leur localisation.

6.1.1 Évolution des fonctions de perte

Smooth-L1 (2015) [7] : optimise les quatre coordonnées (x_1, y_1, x_2, y_2) **indépendamment**, sans considération géométrique globale. *Limitation* : ne correspond pas à la métrique d'évaluation (IoU).

IoU Loss (2016) [8] :

$$\mathcal{L}_{\text{IoU}} = 1 - \text{IoU}(A_{\text{pred}}, A_{\text{gt}}) \quad (6.1)$$

Première perte optimisant l'IoU directement. *Limitation* : gradient nul quand les boîtes ne se chevauchent pas.

GIoU Loss (2019) [9] :

$$\mathcal{L}_{\text{GIoU}} = 1 - \text{IoU} + \frac{|\mathcal{C}| - |A \cup B|}{|\mathcal{C}|} \quad (6.2)$$

où $\mathcal{C}$ est la plus petite boîte englobant A et B . Résout le gradient nul. *Limitation* : convergence lente en phase d'alignement initial.

DIoU Loss et CIoU Loss (2020) [5] : DIoU ajoute la distance entre centres ; CIoU (*Complete-IoU*) intègre en plus la cohérence du ratio d'aspect :

$$\mathcal{L}_{\text{CIoU}} = 1 - \text{IoU} + \underbrace{\frac{d(c_A, c_B)^2}{c^2}}_{\text{distance centres}} + \underbrace{\alpha \cdot v}_{\text{ratio d'aspect}} \quad (6.3)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2, \quad \alpha = \frac{v}{(1 - \text{IoU}) + v} \quad (6.4)$$

CIoU est la perte de référence dans YOLO v5 à YOLO11.

Table 6.1: Évolution des fonctions de perte BBR.

Perte	Année	Facteurs géométriques	Gradient nul	Réf.
Smooth-L1	2015	Coordonnées indépendantes	Non	[7]
IoU Loss	2016	Chevauchement seul	Oui	[8]
GIoU	2019	+ Boîte englobante commune	Non	[9]
DIoU	2020	+ Distance entre centres	Non	[5]
CIoU	2020	+ Ratio d'aspect	Non	[5]

6.1.2 Raffinement itératif à l'inférence

BBR peut aussi désigner des étapes de **raffinement itératif** appliquées à l'inférence. La **Cascade R-CNN** en est l'exemple de référence : trois étapes successives de régression avec des seuils IoU croissants ($0.5 \rightarrow 0.6 \rightarrow 0.7$), permettant un affinement progressif.

6.2 Hypothèses

Hypothèses implicites de BBR

1. Les boîtes peuvent être paramétrées par des coordonnées euclidiennes stables lors de l'entraînement (pas de distorsions géométriques majeures comme en fisheye).
2. L'IoU est une métrique d'apprentissage cohérente avec la métrique d'évaluation, justifiant son utilisation directe comme objectif d'optimisation.
3. Les facteurs géométriques additionnels (distance, ratio d'aspect) améliorent la généralisation sans surapprentissage.

6.3 Analyse des limitations

Limitations de BBR

1. **BBR ne remplace pas NMS** : BBR améliore la précision individuelle des boîtes mais ne traite pas la redondance des détections multiples. Les deux approches sont complémentaires.
2. **Distorsion fisheye** : les projections gnomoniques introduisent des déformations géométriques (boîtes trapézoïdales aux bords) ; CIoU calculée sur ces boîtes déformées peut produire des gradients instables.
3. **Coût du raffinement itératif** : Cascade R-CNN triple le coût de régres-

sion, incompatible avec les contraintes temps-réel embarqué.

6.4 Résultats quantitatifs

6.4.1 Gains des fonctions de perte BBR

Table 6.2: Impact des fonctions de perte BBR sur la précision de localisation — Faster R-CNN, MS-COCO val [5, 9].

Perte	mAP _{50:95}	mAP ₅₀	mAP ₇₅	mAP _S	mAP _L
Smooth-L1 (baseline)	36.4	58.3	39.2	20.1	47.8
IoU Loss	36.8	58.7	39.6	20.5	48.4
GIoU Loss	37.1	58.9	39.9	20.8	48.9
DIoU Loss	37.5	59.2	40.5	21.0	49.2
CIoU Loss	37.9	59.5	40.9	21.3	49.7

6.4.2 Raffinement itératif — Cascade R-CNN

Table 6.3: Cascade R-CNN : gain du raffinement itératif (3 étapes) vs Faster R-CNN standard, MS-COCO val [7].

Architecture	Seuil IoU	mAP _{50:95}	mAP ₅₀	mAP ₇₅	Params (M)
Faster R-CNN (1 étape)	0.50	36.4	58.3	39.2	41.8
Cascade R-CNN (étape 1)	0.50	35.6	57.4	38.0	—
Cascade R-CNN (étape 2)	0.60	37.7	57.9	40.9	—
Cascade R-CNN (étape 3)	0.70	40.3	58.8	43.7	69.2

6.4.3 BBR dans les détecteurs YOLO

Table 6.4: Apport de CIoU vs GIoU dans YOLOv5 et YOLO11 sur MS-COCO val.

Modèle	Perte BBR	mAP _{50:95} (%)	mAP ₅₀ (%)	Gain mAP _{50:95}
YOLOv5s	GIoU	36.6	55.3	baseline
YOLOv5s	CIoU	37.4	56.0	+0.8
YOLO11n	CIoU	39.5	55.9	référence
YOLO26n	Direct (sans DFL)	40.9	57.4	+1.4 vs YOLO11n

La progression Smooth-L1 $\rightarrow$ CIoU apporte un gain cumulatif de $\approx +1.5\%$ mAP_{50:95} sur Faster R-CNN. Dans les détecteurs YOLO, CIoU est la perte de localisation par défaut depuis YOLOv5, contribuant directement à leur supériorité par rapport aux versions antérieures.

7 Weighted Box Fusion (WBF)

7.1 Principe

Proposée par Solovyev *et al.* [6] et publiée dans *Image and Vision Computing* (2021), la **Weighted Box Fusion** représente une **rupture paradigmatique** avec la famille NMS : au lieu de sélectionner une boîte parmi les candidates, WBF les **fusionne toutes** par une moyenne pondérée par les scores de confiance. Aucune boîte candidate n'est supprimée ; toutes contribuent à la boîte finale.

Algorithm 7.1 Weighted Box Fusion (WBF)

Entrées : Boîtes $\mathcal{B}^{(k)}$ de K sources, scores $\mathcal{S}^{(k)}$, seuil cluster θ , seuil de suppression final ϵ

Sorties : Boîtes fusionnées $\mathcal{F}$

```

1: Fusionner et trier toutes les boîtes par scores décroissants
2:  $\mathcal{F} \leftarrow \emptyset$ ,  $\mathcal{L} \leftarrow \emptyset$ 
3: for chaque  $b_i$  (par ordre de score décroissant) do
4:   if  $\exists f^* \in \mathcal{F}$  tel que  $\text{IoU}(b_i, f^*) > \theta$  then
5:     Ajouter  $b_i$  au cluster  $\mathcal{L}[f^*]$ 
6:     Mettre à jour les coordonnées fusionnées :
7:     for  $x \in \{x_1, y_1, x_2, y_2\}$  do
8:        $f_x^* \leftarrow \frac{\sum_{j \in \mathcal{L}[f^*]} c_j \cdot b_{j,x}}{\sum_{j \in \mathcal{L}[f^*]} c_j}$ 
9:     end for
10:     $c_{f^*} \leftarrow \frac{1}{|\mathcal{L}[f^*]|} \sum_{j \in \mathcal{L}[f^*]} c_j$ 
11:   else
12:     Créer  $f_{\text{new}} \leftarrow b_i$  dans  $\mathcal{F}$ 
13:   end if
14: end for return  $\{f \in \mathcal{F} \mid c_f \geq \epsilon\}$ 

```

Les formules de fusion s'écrivent :

$$\hat{x} = \frac{\sum_{j=1}^k c_j \cdot x_j}{\sum_{j=1}^k c_j}, \quad \hat{c} = \frac{1}{k} \sum_{j=1}^k c_j \quad (7.1)$$

Table 7.1: WBF vs NMS et Soft-NMS — ensemble de modèles, MS-COCO [6].

Méthode	mAP val (%)	mAP test-dev (%)
NMS (meilleur modèle seul)	51.2	51.5
Soft-NMS (ensemble)	54.4	54.7
NMW (ensemble)	55.3	55.7
WBF (ensemble)	56.1	56.4

7.2 Hypothèses

Hypothèses implicites de WBF

1. **Complémentarité des sources** : les boîtes issues de modèles ou de projections différentes portent des informations géométriques complémentaires ; leur moyenne pondérée est plus précise qu'une sélection binaire.
2. **Calibration des scores** : un score de confiance élevé indique une meilleure localisation, justifiant une pondération plus forte dans la fusion.
3. **Indépendance des erreurs** : les sources ont des erreurs de localisation indépendantes, permettant leur moyennage pour réduire le bruit géométrique.

7.3 Analyse des limitations

Limitations de WBF

1. **Sous-optimal pour source unique** : en l'absence de diversité de sources (un seul modèle), la fusion n'apporte pas de bénéfice par rapport à NMS.
2. **Coût computationnel plus élevé** : environ $3\times$ plus lent que NMS standard selon l'implémentation [6].
3. **Sensibilité à l'ordre de traitement** : pour des boîtes de scores très proches, l'ordre d'ajout dans les clusters peut varier, entraînant de légères différences de résultat.

WBF — Méthode recommandée pour la fusion inter-projections

Dans ce stage, chaque piéton est détecté depuis 2 à 4 projections gnomoniques. WBF calcule la **moyenne pondérée** de ces boîtes reprojetées, réduisant naturellement le jitter au lieu de supprimer arbitrairement certaines vues. Extension proposée : $w_i = c_i \cdot \delta_i$, où $\delta_i \in (0, 1]$ est la distance normalisée au bord de la projection source (les boîtes centrales, géométriquement plus fiables, contribuent davantage).

8 NMS-Free : Inférence End-to-End sans Post-Traitement

8.1 Contexte et motivation

De YOLOv1 à YOLO11, tous les détecteurs YOLO appliquent une stratégie **one-to-many (O2M)** : plusieurs ancres positives par objet à l'entraînement, puis NMS obligatoire à l'inférence. Cette dépendance cause trois problèmes majeurs [13, 10] :

- **Latence additionnelle** : NMS ajoute ~ 4 ms (GPU T4) ;
- **Hyperparamètres fragiles** : $\mathcal{N}_t$ et τ_c doivent être recalibrés pour chaque domaine ;
- **Obstacle à l'export** : NMS est difficile à intégrer dans les graphes ONNX, TensorRT, CoreML, TFLite.

Les architectures Transformer (DETR, RT-DETR) ont éliminé NMS via le matching hongrois, mais leur latence de forward-pass est $4\times$ plus élevée, incompatible avec les systèmes embarqués [12].

8.2 YOLOv10 : Consistent Dual Assignments (NeurIPS 2024)

8.2.1 Innovation centrale

Wang *et al.* [10] proposent une architecture à **double tête de détection parallèle** :




Figure 8.1: Architecture duale de YOLOv10. À l'inférence, seule la tête O2O est utilisée : NMS n'est plus nécessaire.

- **Tête O2M** : stratégie TAL standard, plusieurs ancres positives par objet. Active uniquement à l'entraînement.
- **Tête O2O** : une seule prédiction par objet (analogue au matching hongrois mais sans son coût). Active à l'entraînement *et* à l'inférence. **Aucun NMS requis.**

Le matching cohérent (**Consistent Matching Metric**) impose les mêmes hyper-

paramètres aux deux têtes [10] :

$$\mathcal{M}(p, \hat{b}; g, b) = p^\alpha \cdot \text{IoU}(\hat{b}, b)^\beta, \quad \alpha_{O2O} = \alpha_{O2M} = 0.5, \quad \beta_{O2O} = \beta_{O2M} = 6 \quad (8.1)$$

Table 8.1: Performances de YOLOv10 sur MS-COCO (GPU T4, latence E2E) [10].

Modèle	mAP (%)	Lat. E2E (ms)	Params (M)	FLOPs (G)
YOLOv10-N	38.5	1.84	2.3	6.7
YOLOv10-S	46.3	2.49	7.2	21.6
YOLOv10-M	51.1	4.74	15.4	59.1
YOLOv10-B	52.5	5.74	19.1	92.0
YOLOv10-L	53.2	7.28	24.4	120.3
YOLOv10-X	54.4	10.70	29.5	160.4

8.3 YOLO26 : NMS-Free Natif et Optimisations Edge

Transparence sur les sources

YOLO26 a été publié en janvier 2026 par Ultralytics. Ce rapport s'appuie sur : documentation officielle [11] ; Sapkota *et al.* [12] ; Chakrabarty [13] ; Hidayatullah *et al.* [14].

8.3.1 Vue d'ensemble

YOLO26 est conçu selon trois principes fondateurs [11] : **(1) Simplicité** : pipeline end-to-end nativement sans NMS ; **(2) Efficacité de déploiement** : suppression de DFL, compatibilité NPU/DSP/microcontrôleurs ; **(3) Innovation d'entraînement** : MuSGD, ProgLoss, STAL.

Il conserve la double tête O2O/O2M de YOLOv10 avec [11] :

- **Tête O2O (défaut)** : sortie $(N, 300, 6)$, max 300 détections par image, sans NMS.
- **Tête O2M (optionnelle)** : mode traditionnel avec NMS, activable via `end2end=False` pour maximiser la précision.

8.3.2 Innovation 1 — Suppression de la DFL

La Distribution Focal Loss (DFL, YOLOv8+) modélisait les coordonnées par une distribution discrète, imposant une opération `softmax` difficile à exporter sur NPU/DSP.

YOLO26 la supprime [11, 14], adoptant la **régression directe des coordonnées**, simplifiant le graphe de calcul et élargissant la compatibilité hardware.

8.3.3 Innovation 2 — ProgLoss

Ordonnanceur dynamique des pondérations de perte au fil des époques [13, 12] :

$$\mathcal{L}^{(t)} = \lambda_{\text{cls}}^{(t)} \mathcal{L}_{\text{cls}} + \lambda_{\text{box}}^{(t)} \mathcal{L}_{\text{box}} + \lambda_{\text{obj}}^{(t)} \mathcal{L}_{\text{obj}} \quad (8.2)$$

En début d’entraînement, la classification est privilégiée ; en fin, la localisation est renforcée. Stabilise la convergence des petits modèles.

8.3.4 Innovation 3 — STAL

STAL (*Small-Target-Aware Label Assignment*) réduit automatiquement le seuil IoU d’assignation pour les petites cibles (ratio surface/image $< \tau_s$), garantissant un signal positif même pour des objets de très faible surface angulaire [13, 11].

8.3.5 Innovation 4 — Optimiseur MuSGD

Hybride SGD et optimiseur Muon (inspiré de Moonshot AI — Kimi K2) [11] :

$$\mathbf{v}_{t+1} = \mu \mathbf{v}_t - \eta_t \nabla \mathcal{L}_t + \gamma \Delta_{\text{Muon}}^{(t)} \quad (8.3)$$

où $\Delta_{\text{Muon}}^{(t)}$ est une correction de courbure locale transférant les techniques d’optimisation des LLMs vers la vision embarquée.

Table 8.2: Performances de YOLO26 sur MS-COCO (tête O2O, end-to-end) [11].

Modèle	mAP (%)	CPU ONNX (ms)	T4 TRT (ms)	Params (M)
YOLO26n	40.9	38.9	1.7	2.4
YOLO26s	48.6	87.2	2.5	9.5
YOLO26m	53.1	220.0	4.7	20.4
YOLO26l	55.0	286.2	6.2	24.8
YOLO26x	57.5	525.8	11.8	55.7

Table 8.3: Comparaison modèles nano — MS-COCO [12, 11].

Modèle	mAP (%)	CPU (ms)	NMS-Free	DFL
YOLOv8n	37.3	~80.4	Non	Oui
YOLO11n	39.5	~56.1	Non	Oui
YOLOv10n	38.5	—	Oui	Oui
YOLO26n	40.9	38.9	Oui	Non

8.4 Hypothèses

Hypothèses implicites de l'approche NMS-Free (YOLO26)

1. La tête O2O peut apprendre une assignation one-to-one aussi discriminante que l'O2M, grâce au signal superviseur conjoint ; la suppression de DFL est compensée par ProgLoss et STAL [11].
2. MuSGD transfère efficacement les techniques LLM vers la vision embarquée ; les dynamiques d'optimisation sont suffisamment similaires malgré des architectures très différentes [11, 12].
3. STAL généralise bien aux petites cibles de distribution variée, pas uniquement celles de COCO — à confirmer sur données fisheye.
4. ProgLoss suppose qu'un ordonnancement privilégiant la classification avant la localisation est universel et optimal pour toutes les variantes de modèles [13].

8.5 Analyse des limitations

Limitations de YOLO26 NMS-Free

1. **Réentraînement obligatoire** : incompatible avec les poids YOLO11 ; la suppression de DFL et la nouvelle tête O2O imposent un entraînement complet.
2. **Léger déficit de précision en mode e2e** : écart de ~0.8% mAP entre mode standard (avec NMS) et mode end-to-end (ex. YOLO26n : 40.9% vs 40.1%) [11].
3. **Benchmarks indépendants encore limités** : analyses ablatives tierces à paraître (publication janvier 2026).
4. **Sensibilité hors distribution** : la tête O2O apprise sur COCO peut produire des doublons sur des distributions fisheye sans fine-tuning.

5. **Polyvalence réduite vs YOLO11** : YOLO11 reste supérieur pour les tâches multi-modalités complexes.

8.6 Intégration NMS-Free avec les Images Fisheye

8.6.1 Contexte du pipeline fisheye multi-projections

L'approche de détection fisheye utilisée dans ce stage repose sur la génération de N projections gnomoniques (patches perspectifs) depuis l'image fisheye 180°, l'application d'un détecteur sur chaque patch, puis la reprojection des boîtes dans le référentiel fisheye. Ce pipeline génère trois problèmes spécifiques :

1. **Redondance inter-projections** : un même piéton détecté depuis 2 à 4 projections produit autant de boîtes reprojettées légèrement décalées.
2. **Jitter géométrique** : les distorsions de reprojection (boîtes trapézoïdales aux bords, élargissement radial) introduisent des erreurs de localisation non-uniformes selon la position dans l'image fisheye.
3. **Asymétrie de confiance** : les piétons proches des bords d'une projection gnomonique (zone de distorsion maximale) reçoivent des scores de confiance plus faibles que les mêmes piétons vus depuis le centre d'une autre projection.

8.6.2 Apport de YOLO26 NMS-Free au niveau intra-projection

L'intégration de YOLO26 NMS-free au niveau de chaque patch gnomonique apporte les avantages suivants :

Bénéfices directs au niveau intra-projection

- **Exactement une boîte par piéton par patch** : la tête O2O garantit une seule prédiction par instance dans chaque projection. Les doublons intra-patch (deux ancres sur le même piéton) sont éliminés structurellement, sans paramètre $\mathcal{N}_t$ à calibrer.
- **Élimination du NMS intra-patch** : NMS n'est plus exécuté dans le pipeline ; le graphe de calcul est simplifié, facilitant l'export vers les accélérateurs embarqués (NPU, NVIDIA Jetson, Raspberry Pi) selon [12].
- **Suppression de DFL** : YOLO26 adopte la régression directe des coordonnées, réduisant la complexité de l'opération de décodage ; particulièrement utile pour les déploiements sur systèmes drone à ressources contraintes.
- **STAL pour les piétons éloignés** : les piétons vus de loin dans l'image fisheye occupent moins de 32×32 px. STAL garantit leur assignation positive lors de l'entraînement — à calibrer sur données fisheye annotées.

8.6.3 Pipeline proposé : YOLO26 + WBF pondéré

YOLO26 NMS-free gère la redondance *intra-patch* ; la WBF pondérée gère la redondance *inter-projections* :




Figure 8.2: Pipeline proposé. YOLO26 NMS-free élimine les doublons *intra-patch* ; WBF pondérée fusionne les boîtes *inter-projections* en réduisant le jitter.

La pondération WBF modifiée intègre la qualité géométrique selon la position dans la projection :

$$w_i = c_i \cdot \delta_i \quad (8.4)$$

où c_i est le score de confiance YOLO26 et $\delta_i \in (0, 1]$ est la distance normalisée de la boîte b_i au bord le plus proche de sa projection source. Les boîtes centrales (distorsion minimale, reprojection la plus précise) contribuent davantage à la boîte finale.

8.6.4 Points d'attention pour l'intégration

1. **Fine-tuning indispensable** : la tête O2O de YOLO26 est entraînée sur COCO (boîtes axis-alignées, scènes standard). Sur des données fisheye, les distributions de boîtes sont atypiques (formes trapézoïdales, ratios d'aspect inhabituels). Un fine-tuning sur un dataset fisheye annoté est indispensable.
2. **Calibration de τ_s (STAL)** : le seuil de petites cibles doit être ajusté en fonction de la résolution de l'image fisheye et de la taille apparente des piétons à la hauteur de vol du drone.
3. **Calibration de θ (WBF)** : le seuil de clustering de WBF doit tenir compte des distorsions de reprojection, qui augmentent l'IoU apparent entre boîtes du même piéton.
4. **Stabilisation temporelle** : un filtre de Kalman ou une moyenne exponentielle (EMA) sur les boîtes finales peut réduire le jitter résiduel inter-frames.

9 Analyse Comparative et Synthèse

Table 9.1: Synthèse comparative des méthodes étudiées selon les critères du contexte du projet.

Méthode	Sc. denses	Multi-vues	Fusion coord.	Réentr.	Complexité
NMS Standard	×	×	Non	Non	$O(n^2)$
Soft-NMS	~	~	Non	Non	$O(n^2)$
DIoU-NMS	+	+	Non	Non	$O(n^2)$
Adaptive NMS	++	~	Non	Oui	$O(n^2)$
BBR (CIoU)	—	—	Oui	Oui	Entraîn.
WBF	++	++	Oui	Non	3×NMS
NMS-Free (YOLO26)	+	+	Partiel	Oui	$O(1)$ E2E

Guide de sélection pour ce stage

- **Amélioration immédiate sans réentraînement** : Soft-NMS (+0.5 à +1.7% mAP, plug-and-play).
- **Foule dense (CrowdHuman)** : Adaptive NMS (-3.4% MR⁻²) si réentraînement possible.
- **Fusion inter-projections fisheye (jitter)** : WBF avec $w_i = c_i \cdot \delta_i$.
- **Détecteur sans NMS, latence minimale** : YOLO26 NMS-free + fine-tuning fisheye.
- **Précision de localisation à l'entraînement** : CIoU Loss.
- **Objets orientés** : YOLO26 NMS-free.

10 Conclusion

Ce rapport a présenté de manière structurée et exhaustive sept méthodes de post-traitement en détection d'objets, chacune analysée selon son **principe**, ses **hypothèses implicites** et ses **limitations**.

La progression naturelle observée est la suivante : NMS Standard pose les bases mais

échoue en scènes denses ; Soft-NMS assouplit la suppression ; DIoU-NMS l'enrichit géométriquement ; Adaptive NMS la rend contextuelle. BBR améliore la qualité de localisation orthogonalement à NMS ; WBF change de paradigme en fusionnant au lieu de supprimer. YOLO26 va plus loin en éliminant NMS architecturalement.

Pour ce stage spécifiquement, le pipeline **YOLO26 NMS-Free + WBF pondérée** constitue l'architecture la plus prometteuse : YOLO26 élimine les doublons intra-projection structurellement ; WBF fusionne les boîtes inter-projections en réduisant le jitter ; la vectorisation GPU du pipeline complet est facilitée par l'absence de NMS.

Références

References

- [1] A. Neubeck and L. Van Gool, *Efficient Non-Maximum Suppression*, 18th Int. Conf. on Pattern Recognition (ICPR), pp. 850–855, 2006.
- [2] R. Bodla, B. Singh, R. Chellappa and L. Davis, *Soft-NMS — Improving Object Detection with One Line of Code*, IEEE Int. Conf. on Computer Vision (ICCV), pp. 5561–5569, 2017.
<https://arxiv.org/abs/1704.04503>
- [3] B. Jiang et al., *Acquisition of Localization Confidence for Accurate Object Detection*, ECCV, pp. 816–832, 2018.
<https://arxiv.org/abs/1807.11590>
- [4] S. Liu, L. Huang and Y. Wang, *Adaptive NMS: Refining Pedestrian Detection in a Crowd*, IEEE CVPR, pp. 9855–9864, 2019.
<https://arxiv.org/abs/1904.03629>
- [5] Z. Zheng, P. Wang, W. Liu, J. Li, R. Ye and D. Ren, *Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression*, AAAI, pp. 12993–13000, 2020.
<https://arxiv.org/abs/1911.08287>
- [6] R. Solovyev, W. Wang and T. Gabruseva, *Weighted Boxes Fusion: Ensembling Boxes from Different Object Detection Models*, Image and Vision Computing, vol. 107, 2021.
<https://arxiv.org/abs/1910.13302>
- [7] S. Ren, K. He, R. Girshick and J. Sun, *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*, NeurIPS, vol. 28, 2015.
<https://arxiv.org/abs/1506.01497>
- [8] J. Yu, Y. Jiang, Z. Wang, Z. Cao and T. Huang, *UnitBox: An Advanced Object Detection Network*, ACM Multimedia, pp. 516–520, 2016.
- [9] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid and S. Savarese, *Generalized Intersection over Union*, IEEE CVPR, pp. 658–666, 2019.
<https://arxiv.org/abs/1902.09630>
- [10] A. Wang, H. Chen, L. Liu et al., *YOLOv10: Real-Time End-to-End Object Detection*, NeurIPS, 2024.
<https://arxiv.org/abs/2405.14458>

- [11] G. Jocher and J. Qiu, *Ultralytics YOLO26*, Ultralytics, janvier 2026.
<https://docs.ultralytics.com/models/yolo26/>
- [12] R. Sapkota, R. H. Cheppally, A. Sharda and M. Karkee, *YOLO26: Key Architectural Enhancements and Performance Benchmarking for Real-Time Object Detection*, arXiv:2509.25164, dernière révision janv. 2026.
<https://arxiv.org/abs/2509.25164>
- [13] S. Chakrabarty, *YOLO26: An Analysis of NMS-Free End to End Framework for Real-Time Object Detection*, arXiv:2601.12882, 2026.
<https://arxiv.org/abs/2601.12882>
- [14] P. Hidayatullah et al., *NMS-Free End-to-End Object Detection Framework Analysis*, arXiv:2602.14582, 2026.
<https://arxiv.org/abs/2602.14582>
- [15] R. Seidel, A. Apitzsch and G. Hirtz, *Improved Person Detection on Omnidirectional Images with Non-Maxima Suppression*, arXiv:1805.08503, 2018.
<https://arxiv.org/abs/1805.08503>
- [16] S.-H. Chiang, T. Wang and Y.-F. Chen, *Efficient Pedestrian Detection in Top-View Fisheye Images Using Compositions of Perspective View Patches*, Image and Vision Computing, vol. 105, 104069, 2021.
<https://doi.org/10.1016/j.imavis.2020.104069>